大数据项目综合实训 · 期末汇报

豆瓣高分影视作品

1052 部作品的采集、清洗、可视化与文本建模

1052 部

影视作品

候选池 1131 部，资料完整 1052 部

电影 539 / 剧集 513

4695 条

热门短评

覆盖 939 部作品

每部固定取 5 条

942 部

含评分分布

五星到一星的占比

全部来自作品页

7 个

模型横向对比

5 折交叉验证

指标全部 out-of-fold

汇报人：A / B / C / D · 2026 年 10 月

采集 · 清洗 · 可视化 · 建模

OVERVIEW

一页看懂这个项目

四个阶段各自独立可复现：采集 → 清洗 → 可视化 → 建模

1052 部

影视作品

候选池 1131 → 成品 1052

电影 539 / 剧集 513

4695 条

热门短评

覆盖 939 部作品

每部固定 5 条

4612 条

建模样本

去掉未打星与空文本

5 星 57.5% / 4 星及以下 42.5%

16 屏

可视化页面

ECharts + HTML/CSS/JS

离线双击即可演示

一句话结论

短评文本里确实存在“态度”信息，但弱到不足以支撑一个实用分类器 —— 最好的模型 AUC 0.647、准确率 60.6%，只比“全部猜 5 星”的基线高 3.1 个百分点，而且没有跑赢“同片其他短评的多数票”。

PIPELINE

四个阶段

每一段都有独立的脚本和产物，从任意一段都能重新跑通

01

采集

· 免登录抓公开页面

· 主通路一页同时拿资料、评分分布、短评

· 1131 个候选 → 1052 部成品

02

清洗与特征

· 两张分析表 1052×60、4695×26

· 类型 / 年代 / 国家结构化

· 文本长度、标点、情感等特征

03

可视化

· ECharts 六屏可切换

· 9 张图表 + 6 张 KPI

· 双击离线打开，不需要服务器

04

文本建模

· 5 折交叉验证，指标全部 out-of-fold

· 7 个模型横向对比

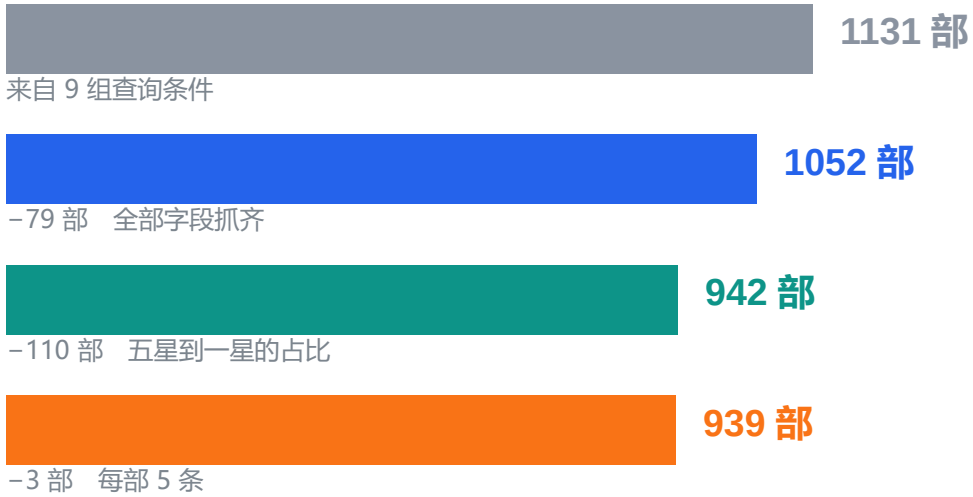
· 文本模型 vs 无文本基线

1131	1052	942	4695	6	7
候选作品	资料完整	含评分分布	条短评	屏可视化	个模型

COLLECT

采集：从 1131 个候选到 4695 条短评

免登录、只读公开页面；主通路把请求量从约 3000 次压到约 1000 次



→ 4695 条短评（939 部 × 每部 5 条）

漏斗只画作品数（1131 → 939），不把 4695 条短评按比例放大 —— 作品数和短评数是两个量级不同的单位，放大就是失真。

采集工程

进度全部落 SQLite，断点续爬自动跳过已完成；导出 CSV / Excel 用 UTF-8 BOM，双击不乱码。

主通路：电脑端作品页

`movie.douban.com/subject/<id>/`

一页同时给出：全部资料 + 五星到一星的占比 + 约 5 条热门短评。

把请求量从约 3000 次压到约 1000 次。

辅助：手机端详情接口

`m.douban.com/rexxar/api/v2/movie/<id>`

返回 30 多个字段的 JSON，但会按 IP 限流，所以只做补充。

DEFENSE

四种反爬，和把它们驯服下来的节奏

全部是实测遇到的真实形态，不是文档推测

01 IP 限流

- HTTP 400
- body 里 code=1309
- subject_ip_rate_limit
- 整台机器一段时间内被拒

02 全站 403

- 连首页都打不开
- 持续 30 分钟以上
- 换出口 IP 后立刻恢复
- 不能猛试探

03 工作量证明

- sha512 挑战页
- 要算 nonce 让哈希前缀为 0
- POST 时不能带 Origin 头
- 带了直接 403

04 验证码墙

- 腾讯 TCaptcha「禁止访问」
- 1041 字节的空壳页
- 代码解不了
- 2~3 分钟自动解除

最后定下来的节奏（写死在配置文件里）

6~9 秒	9 次	180 秒	2.0~2.1 部/分钟	0 条
每次请求间隔	主动休息一次	每次休息时长	实测稳定速度	整夜运行的失败数

代价是慢：抓满 1000 部要一整天；换来的是整夜连续运行 0 条失败。

CLEAN

清洗与特征工程

把数据库里的原始记录，变成两张可以直接拿来做分析和建模的宽表

analysis_movies.csv

1052 行 × 60 列，一行一部作品

资料 + 评分分布 + 每部短评的聚合结果

analysis_comments.csv

4695 行 × 26 列，一行一条短评

原文 + 清洗文本 + 文本特征 + 时间拆解

清洗做了什么

· SQLite 里 year / votes 是文本，统一转成数字再参与计算

· 评分统一成 2 位小数，缺失值与 0 分开处理，不混为一谈

· 类型、国家按分隔符拆成列表，再做 Top15 的 one-hot

· 年限换算成年代，评价人数取对数，避免长尾压平坐标轴

· 短评正文去表情、去多余空白，另存一列保留原文

脚本：analysis/01_build_dataset.py（只用标准库，可重跑）

生成了哪些特征

作品级

· good_rate / bad_rate（好评率、差评率）

· polarization = 五星占比 − 一星占比

· log_votes、duration_min、decade、is_top250

短评级

· 字数、标点个数、问号 / 省略号 / 表情有无

· 星级标签、发布时间拆成 年 / 月、IP 归属地

聚合级

· 每部作品的短评数、平均字数、平均星级

QUALITY

数据质量自检：6 项全部通过

每一条都可以在数据库里复现，不是口头保证

✓ 五星到一星占比之和

偏离 100% 超过 1.2 个百分点的：0 部

✓ 平均分与评分分布

两者同进同退，0 个例外

✓ 短评关键字段

正文 / 时间 / 作者名 / 作者 id 空值：0 条

✓ 每部作品的短评条数

最小值 = 最大值 = 5（覆盖 939 部）

✓ 数据库完整性

PRAGMA integrity_check = ok

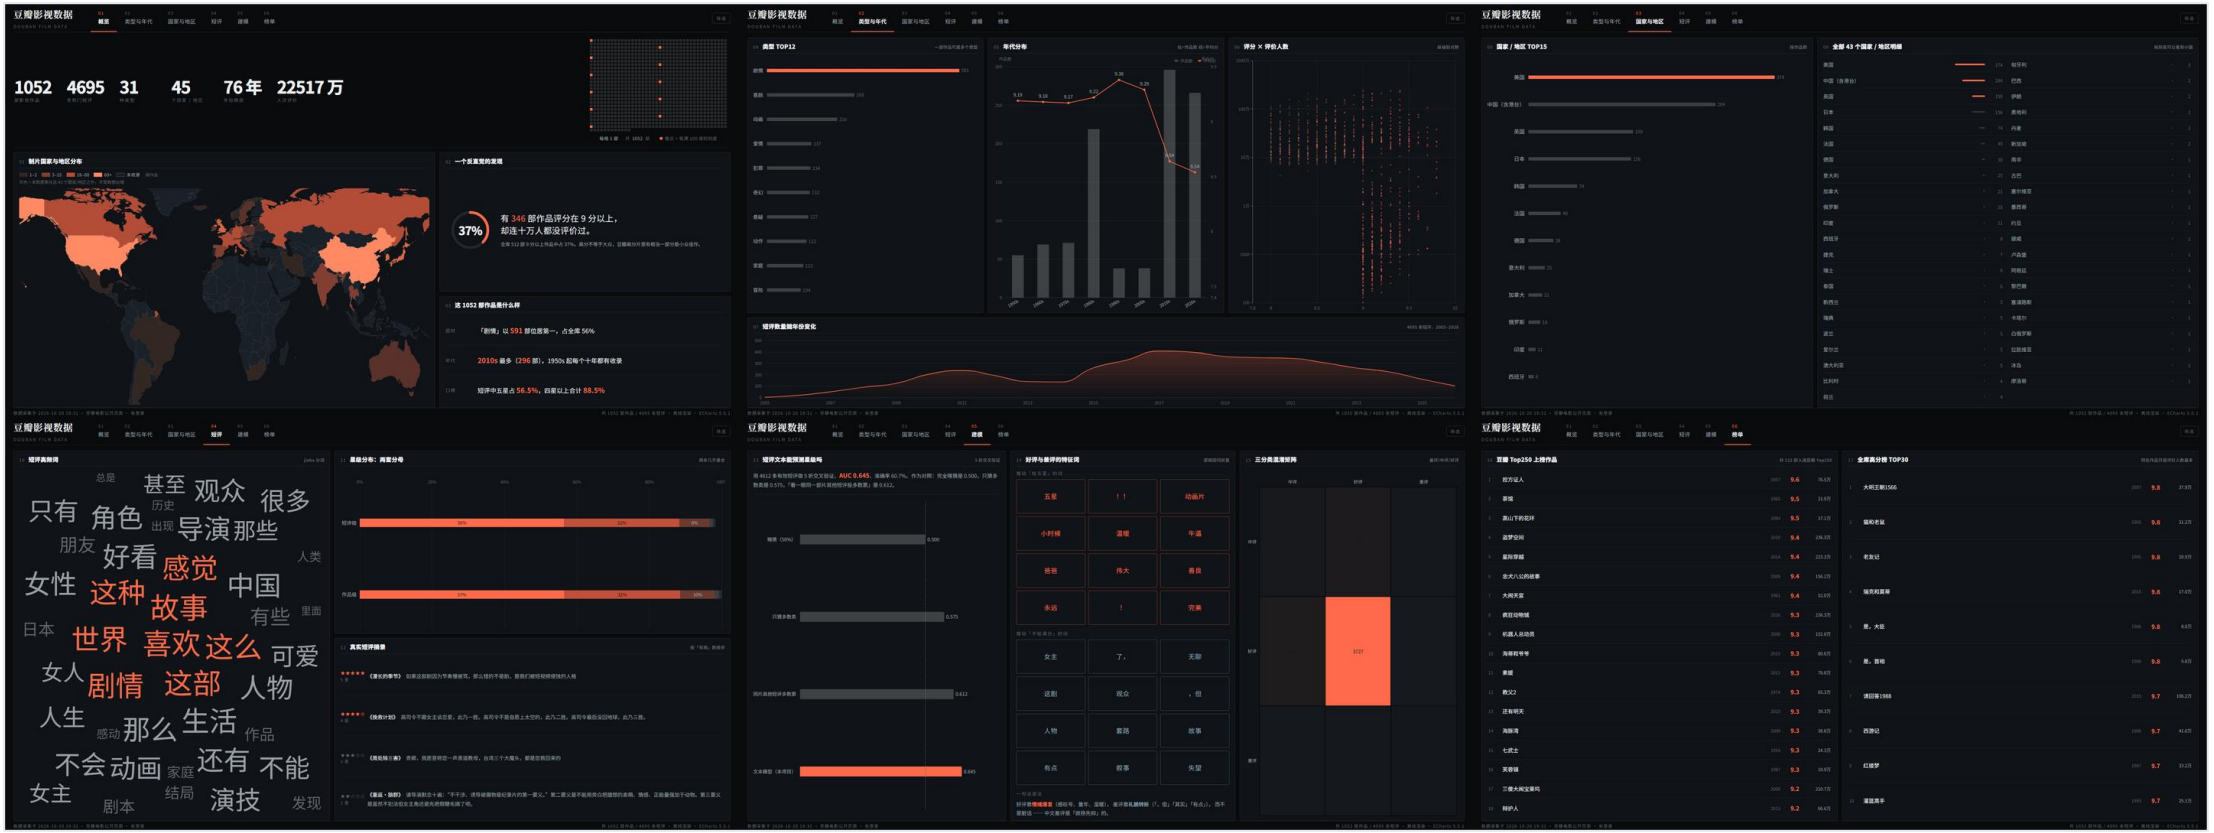
✓ 抽样人工核对

与豆瓣页面逐字比对一致

VISUAL

可视化页面：六屏可切换

ECharts 5.5.1 + 原生 HTML/CSS/JS，全部本地化，双击 index.html 即可离线演示



01 概览　02 类型与年代　03 国家与地区　04 短评口碑　05 文本建模　06 榜单

顶部编号导航切换，200 毫秒淡入；每屏都是“一句结论 + 若干图表”的结构，不用滚动、不用点击图例。

VISUAL

读图 · 类型与年代

截图来自我们自己的页面，不是示意图



剧情占了一半以上

591 部，占全部作品的 56.2% —— 高分影视的“主流”就是剧情片。

年代平均分几乎没有差别

八个十年都在 9.17~9.38 之间，说明这不是“老片更好”。

2010s 与 2020s 略低

不是质量下降，而是这两个年代的作品数最多，把均值拉平了。

VISUAL

读图 · 国家与短评口碑

左：作品的国家与地区分布　右：短评的星级与高频词



03 国家与地区 · 45 个国家和地区、1297 个国籍名额



04 短评口碑 · 4695 条短评的星级与高频词

合拍片会被重复计数

美国 374、中国大陆 218…… 各国相加是 1297，比作品数 1052 多 —— 因为一部合拍片每个参与国都算一次。

好评多，差评写得长

5 星占 56.46%、4 星占 31.86%，两者合计 88.3%；而 1~2 星的中位字数明显更长。

FINDINGS

三个发现，和一个差点讲错的假信号

每个结论都指向具体的图，不接受“感觉上”

发现

01 346 部高分作品没有热度

评分 9 分以上、评价人数不足 10 万的，占全库 36.7%。

02 “高分”更像口味而不是共识

9 分作品里评价人数中位数只有 1 万多，样本越少越容易冲高。

03 短评的态度是“弱信号”

文本能区分 5 星和 1~2 星（AUC 0.700），但分不开 4 星和 5 星（0.623）。

假信号

大屏上 1990s / 2000s 的平均分只有 2.72 / 5.13，看起来像“老片更差”。

真实原因

这两个年代分别只有 11/38、21/38 部抓到了评分分布；全库缺评分的 110 部里，44 部挤在这两个只占作品总数 7% 的年代。

教训：每张图先问一句“分母是谁”。

MODEL

建模任务：为什么不用“3 星以上即好评”

标签怎么定，决定了后面所有数字有没有意义

原始标签：3 星以上算好评

在这份数据上是 98.4% : 1.6%（4539 : 75）—— 什么都不看、全猜“好评”就有 98.4% 的准确率。

这样的标签没有信息量，模型好坏都测不出来。

改用：5 星 vs 4 星及以下

比例是 57.5% : 42.5%（2651 : 1963），基线从 98.4% 降到 57.5% —— 模型每提高一个点都是真本事。

可用样本 4612 条（去掉 81 条没打星、2 条空文本）。

评估三件套

5 折交叉验证

StratifiedKFold，随机种子 42，每一折都保持类别比例

指标全部 out-of-fold

每个样本的预测都来自没见过它的那一折，不偷看训练集

永远同时报基线

多数类基线 + 两条“不看文本”的基线，否则数字没有参照

MODEL

七个模型的成绩单

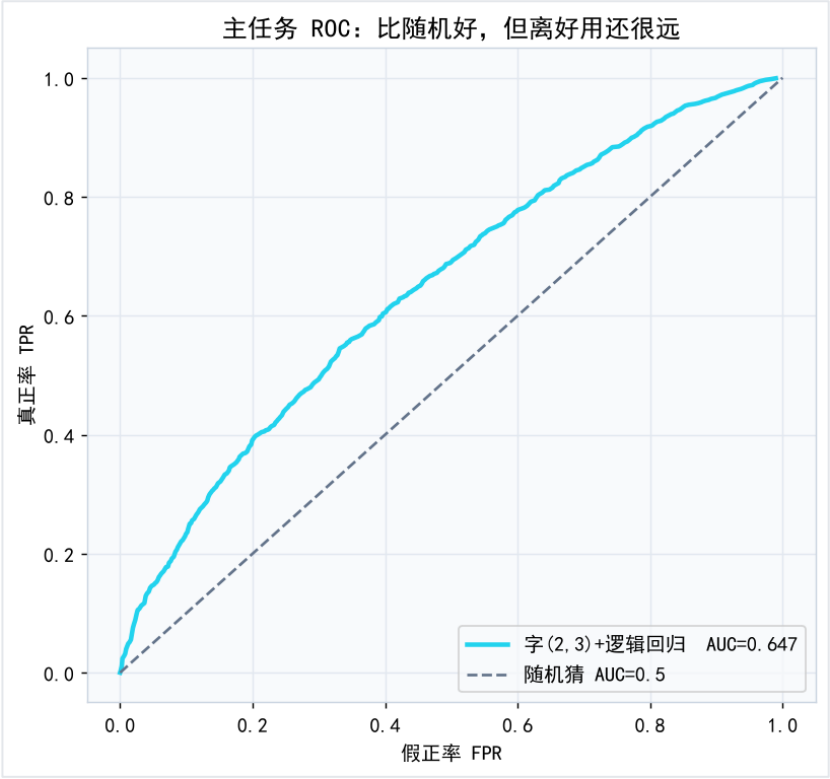
同一套 5 折交叉验证、同一批 4612 条样本，指标全部 out-of-fold

模型	准确率	macro-F1	AUC
词袋 (1,2) + 线性 SVM	0.5752	0.5655	0.6009
词袋 (1,2) + 逻辑回归	0.5880	0.5803	0.6212
词频 (1,2) + 朴素贝叶斯	0.5987	0.5800	0.6224
字符 (2,3) + 线性 SVM	0.5939	0.5829	0.6237
字符 (2,3) + 逻辑回归　← 最好	0.6060	0.5990	0.6465
词 + 字拼接 + 线性 SVM	0.5930	0.5818	0.6223
词 + 字拼接 + 逻辑回归	0.6067	0.5991	0.6449

两条“不看文本”的参照

全部猜 5 星（多数类基线）	**0.5748**	什么都不看
同片其他短评的多数票	**0.6123**	不看文本，反而更高

注意：同片多数票比我们最好的文本模型还高 0.6 个百分点 —— 这个结果我们没有藏，它说明“同伴怎么看”比“文本怎么说”更有效。

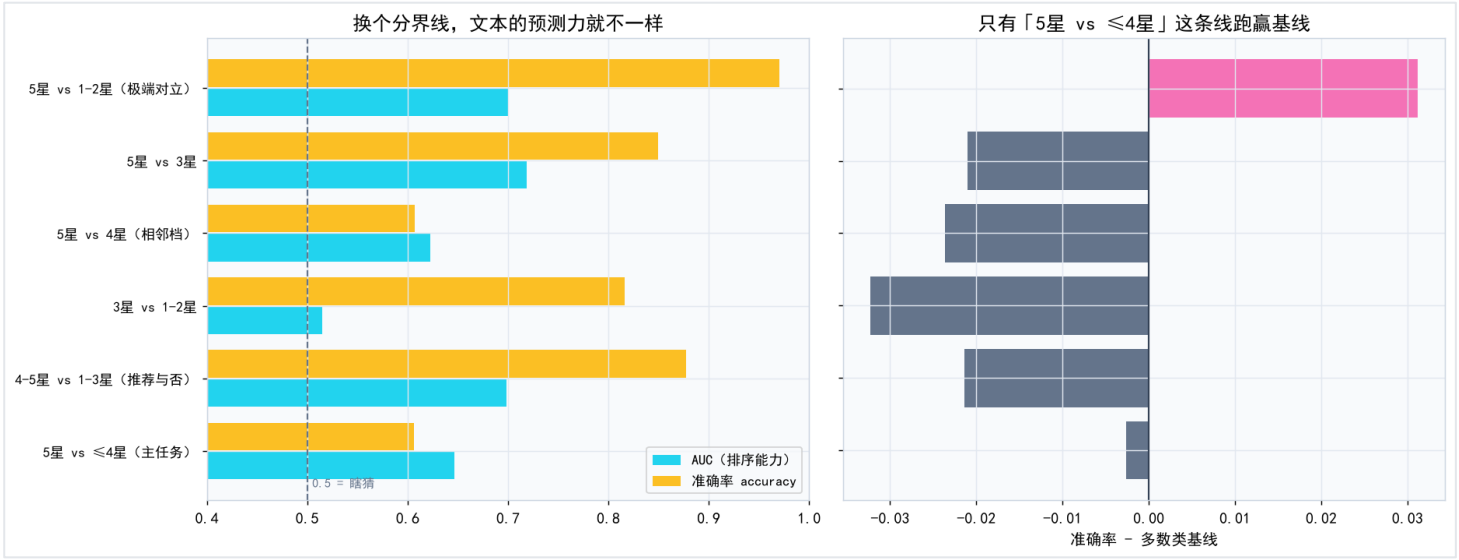


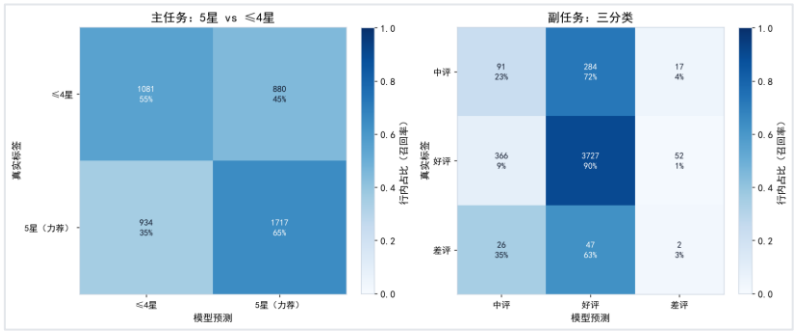
主任务 ROC 曲线：模型确实跑在随机线之上，但离“能用”还差得远。

MODEL

边界在哪里：文本能分开什么，分不开什么

把“5 星 vs 4 星及以下”这条线换成别的线，模型能力立刻现形





态度差距越大，越分得开

5 星 vs 1~2 星 AUC 0.700，5 星 vs 3 星 0.718，而 5 星 vs 4 星只有 0.623。

相邻的 4 星与 5 星，文本上本就模糊

这是标注本身的主观性，不是模型不行。

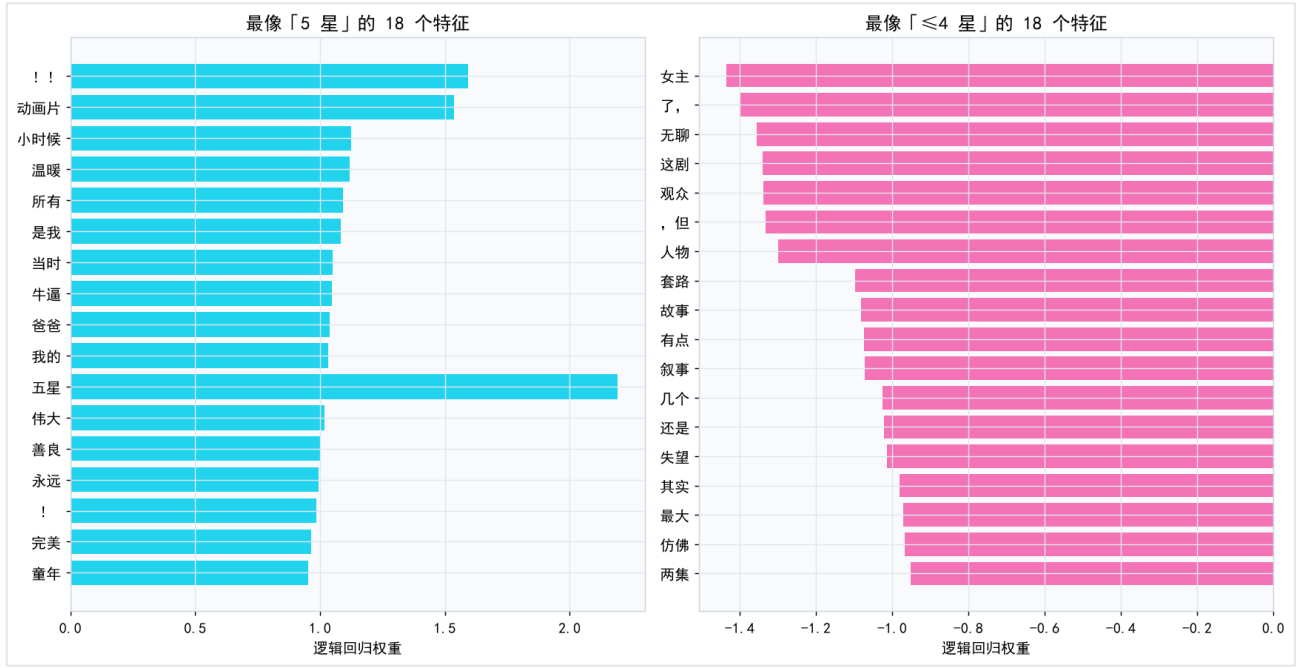
3 星 vs 1~2 星 AUC 0.515 ≈ 瞎猜

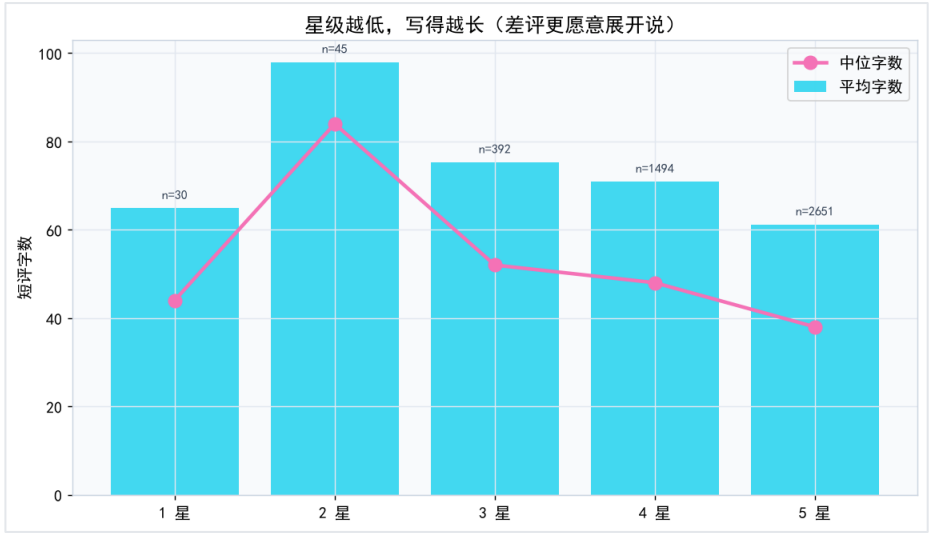
样本只有 467 条，且两类人的用词高度重叠。

MODEL

文本里真正的信号是什么

模型权重最高的词，告诉我们的其实是中文影评的写法





最反直觉的一点：差评靠的是“礼貌的转折”，不是脏话

负向权重最高的字组是“，但”“其实”“有点”“还是”，而不是“难看”“垃圾”。中文影评习惯欲扬先抑，模型学到的是句式结构；另外 5 星的中位字数是 38，2 星是 84 —— 差评写得更长。

图上“五星”那根特别长的条是标签泄漏：150 条短评（3.25%）直接提到了星级，全部剔除后 AUC 从 0.6465 掉到 0.6425，结论不变。

SUMMARY

结论

我们做了什么、发现了什么、哪里还没做好

做完了什么

· 从零写了免登录爬虫，稳定跑完 1052 部作品、4695 条短评

· 两张分析宽表 + 一套六屏离线可视化页面

· 7 个模型横向对比，全部指标 out-of-fold

发现了什么

· 短评文本里确实有态度信号，但是弱信号

· 判题材（动画 vs 剧情 AUC 0.805）远比判态度容易

· “高分”不等于“共识”：346 部 9 分作品热度不足 10 万

哪里还能更好

· 110 部作品缺评分分布，两个年代的均值因此失真

· 每部只取了 5 条短评，样本偏“热门”，存在选择偏差

· 没做超参数搜索，也没试预训练语言模型

同一套文本、同一套方法，只把任务从“判态度”换成“判题材”，准确率从 60.6% 升到 78.5%。

谢谢 • 欢迎提问